

Guía de Deploy en

Oracle Cloud Infrastructure

Agente RAG — alura-agente-rag-pro

Documentación completa del proceso de configuración de red,
creación de instancia y despliegue de aplicación en OCI Always Free

Autor	Ian Beltran (ianjaner55)
Fecha	24 de July de 2026
Región OCI	sa-bogota-1 (Colombia Central)
VCN	vcn-alura-agente
Stack	Python · LangChain · FAISS · Groq · Supabase · Streamlit
Repo	github.com/ianjaner75/-alura-agente-rag-pro

Contenido

1. Introducción y contexto del proyecto
2. Arquitectura general
3. Fase 1 — Configuración de la Red Virtual (VCN)
4. Fase 2 — Security List: reglas de red
5. Fase 3 — Creación de la instancia ARM A1
6. Fase 4 — Conexión SSH y configuración del servidor
7. Fase 5 — Deploy de la aplicación
8. Problemas encontrados y soluciones
9. Referencia rápida de comandos
10. Glosario de términos OCI

1. Introducción y contexto del proyecto

Este documento describe el proceso completo para desplegar una aplicación web basada en Python/Streamlit sobre una instancia gratuita de Oracle Cloud Infrastructure (OCI). El proyecto específico es un Agente RAG (Retrieval-Augmented Generation) desarrollado como parte del challenge de Alura + Oracle ONE.

OCI ofrece un plan Always Free que incluye instancias ARM Ampere A1 con hasta 4 OCPUs y 24 GB de RAM en total, sin costo por tiempo indefinido. Esto lo hace ideal para alojar aplicaciones de aprendizaje automático que no requieren GPU.

Stack tecnológico del proyecto:

Componente	Tecnología	Rol
Frontend	Streamlit	Interfaz de usuario web
Embeddings	HuggingFace all-MiniLM-L6-v2	Vectorización de texto (local, sin cuota)
Vector Store	FAISS	Búsqueda semántica de documentos
LLM	Groq LLaMA 3.1 8B	Generación de respuestas
Persistencia	Supabase (PostgreSQL)	Chats guardados y documentos
Orquestación	LangChain	Pipeline RAG y memoria conversacional

2. Arquitectura general

El siguiente diagrama muestra cómo se conectan los componentes cuando la aplicación está desplegada en OCI:

```
INTERNET
|
v
OCI Virtual Cloud Network (vcn-alura-agente / 10.0.0.0/16)
|
+-- Subred Publica (10.0.0.0/24)
| |
| +- Security List: puerto 22 (SSH) y 8501 (Streamlit)
| |
| +- VM.Standard.A1.Flex (2 OCPU / 12 GB RAM)
| Oracle Linux 8
| |
| +- iptables: puertos 22 y 8501
| +- Python venv
| +- Streamlit :8501
| |
| +- LangChain + FAISS (local)
| +- HuggingFace Embeddings (local)
| +- Groq API (externo)
| +- Supabase (externo)
|
+-- Subred Privada (10.0.1.0/24) [no usada en este deploy]
|
+-- Internet Gateway
+-- Default Route Table
+-- DHCP Options
```

Nota: OCI tiene dos capas de firewall independientes. Ambas deben estar configuradas correctamente para que el tráfico llegue a la aplicación: el Security List (nivel de red OCI) y iptables (firewall del sistema operativo).

3. Fase 1 — Configuración de la Red Virtual (VCN)

Una VCN (Virtual Cloud Network) es la red privada donde viven todas las instancias de OCI. A diferencia de GCP, OCI no crea una red por defecto: hay que crearla manualmente antes de poder lanzar cualquier instancia.

3.1 Crear la VCN con el Wizard

El wizard de OCI es la forma mas rapida de crear una VCN completa con todos sus componentes. Crea automaticamente la VCN, subnets, Internet Gateway y tabla de rutas.

Pasos:

1. Ir a: Menu (hamburguer) > Networking > Virtual Cloud Networks
2. Clic en "Start VCN Wizard"
3. Seleccionar "Create VCN with Internet Connectivity" > Next
4. Completar el formulario con los siguientes valores:

Campo	Valor usado	Explicacion
VCN Name	vcn-alura-agente	Nombre identificador de la red
IPv4 CIDR Block	10.0.0.0/16	Rango de IPs privadas (65,536 IPs disponibles)
Public Subnet CIDR	10.0.0.0/24	Subred publica para instancias accesibles desde internet
Private Subnet CIDR	10.0.1.0/24	Subred privada (no usada en este proyecto)
DNS Resolution	Activado	Resolucion DNS dentro de la VCN

5. Clic en "Next" > Revisar el resumen > Clic en "Create"

El wizard tarda aproximadamente 30 segundos. Al terminar, la VCN aparece en estado Available junto con sus dos subnets.

3.2 Componentes creados automaticamente

Componente	Nombre generado	Funcion
VCN	vcn-alura-agente	Contenedor principal de la red
Subred publica	subred publica-vcn-alura-agente	Instancias accesibles desde internet
Subred privada	subred privada-vcn-alura-agente	Instancias sin acceso desde internet
Internet Gateway	internet-gateway-vcn-alura-agente	Puerta de salida/entrada a internet
Route Table	default route table for vcn-alura-agente	Reglas de enrutamiento de trafico
DHCP Options	Default DHCP Options	Asignacion automatica de IPs y DNS
Security List publica	Default Security List	Firewall de red para la subred publica
Security List privada	lista de seguridad para subred privada	Firewall de red para la subred privada

4. Fase 2 — Security List: reglas de red

El Security List es el primer firewall de OCI. Controla que trafico puede entrar (Ingress Rules) y salir (Egress Rules) de las instancias en una subred. Es obligatorio configurarlo antes de crear la instancia; de lo contrario, ninguna conexion externa funcionara.

IMPORTANTE: OCI tiene DOS capas de firewall. El Security List filtra el trafico a nivel de red (antes de llegar al servidor). Dentro del servidor, iptables filtra nuevamente. Ambos deben permitir el trafico para que la aplicacion sea accesible.

4.1 Como acceder al Security List correcto

1. Menu > Networking > Virtual Cloud Networks
2. Clic en vcn-alura-agente
3. En la seccion Subnets, clic en 'subred publica-vcn-alura-agente'
4. En la seccion Security Lists, clic en 'Default Security List for vcn-alura-agente'
5. Clic en 'Add Ingress Rules'

Atencion: el Security List de la subred PRIVADA es diferente. Asegurate de estar en el de la subred PUBLICA.

4.2 Reglas de Ingress configuradas

Las siguientes reglas permiten que el trafico externo llegue a la instancia:

Stateless	Source	Protocolo	Puerto	Descripcion
No	0.0.0.0/0	TCP	22	SSH — acceso remoto al servidor
No	0.0.0.0/0	ICMP	3,4	ICMP fragmentacion (requerido por OCI)
No	10.0.0.0/16	ICMP	3	ICMP interno entre subnets
No	0.0.0.0/0	TCP	8501	Streamlit — aplicacion web publica

4.3 Regla de Egress

Por defecto existe una regla de egress que permite todo el trafico saliente. No es necesario modificarla.

Stateless	Destino	Protocolo	Puerto	Descripcion
No	0.0.0.0/0	All Protocols	All	Todo el trafico saliente

5. Fase 3 — Creacion de la instancia ARM A1

La instancia es la maquina virtual donde corra la aplicacion. OCI Always Free permite crear una instancia ARM A1 con hasta 4 OCPUs y 24 GB de RAM (distribuidos como se desee entre 1 o 4 instancias). Para este proyecto se usa una sola instancia con 2 OCPUs y 12 GB.

5.1 Navegar al formulario

Menu (hamburger) > Compute > Instances > Create Instance

5.2 Configuracion de la instancia

Campo	Valor	Por que
Name	rag-agent-vm	Nombre descriptivo del servidor
Compartment	ianjaner55 (root)	Compartimento de la cuenta
Availability Domain	AD-1	Unico AD disponible en Bogota
Image	Oracle Linux 8 (2026.07.20)	Ubuntu no tenia shapes ARM disponibles en la region
Shape	VM.Standard.A1.Flex	Shape ARM Always Free-eligible
OCPUs	2	Maximo recomendado para la app RAG
Memory	12 GB	HuggingFace + LangChain requieren al menos 6-8 GB
Network Bandwidth	2 Gbps	Asignado automaticamente segun OCPUs
Primary Network	vcn-alura-agente	La VCN creada en la Fase 1
Subnet	subred publica-vcn-alura-agente	Subred publica para acceso externo
Public IPv4	Automaticamente asignada	Necesaria para acceder desde internet
SSH Keys	RSA generada por OCI	Par de llaves para acceso SSH seguro
Boot Volume	46.6 GB (defecto)	Suficiente para el SO y la aplicacion

5.3 SSH Key — Generacion manual (metodo alternativo)

Si se prefiere generar la llave manualmente en lugar de usar la generada por OCI, ejecutar en Git Bash (Windows):

```
ssh-keygen -t ed25519 -C "oci-rag" -f ~/.ssh/oci_rag_key
```

Esto genera dos archivos: oci_rag_key (privada, nunca compartir) y oci_rag_key.pub (publica, la que se sube a OCI).

Para ver la clave publica y copiarla al formulario de OCI:

```
cat ~/.ssh/oci_rag_key.pub
```

5.4 Guardar la llave privada

Si OCI genera el par de llaves automaticamente, descargar el archivo .key inmediatamente — OCI no lo muestra de nuevo. Guardarlo en una ubicacion segura fuera del repositorio de Git.

6. Fase 4 — Conexion SSH y configuracion del servidor

Una vez la instancia esta en estado Running y tiene una IP publica asignada, se puede acceder al servidor por SSH para instalar las dependencias.

6.1 Conectarse al servidor

En Git Bash (Windows), reemplazar IP_PUBLICA con la IP que aparece en la consola OCI:

```
# Para Oracle Linux 8 (usuario por defecto: opc) ssh -i ~/.ssh/oci_rag_key  
opc@IP_PUBLICA # Para Ubuntu (usuario por defecto: ubuntu) ssh -i  
~/.ssh/oci_rag_key ubuntu@IP_PUBLICA
```

6.2 Abrir el firewall del sistema operativo

Oracle Linux 8 usa firewalld (no iptables). Ubuntu usa iptables. Este es el segundo firewall mencionado en la arquitectura.

Comandos para Oracle Linux 8:

```
sudo firewall-cmd --permanent --add-port=8501/tcp sudo firewall-cmd --permanent  
--add-port=22/tcp sudo firewall-cmd --reload sudo firewall-cmd --list-ports #  
verificar
```

Comandos equivalentes para Ubuntu:

```
sudo iptables -I INPUT -p tcp --dport 8501 -j ACCEPT sudo iptables -I INPUT -p tcp  
--dport 22 -j ACCEPT sudo apt install -y iptables-persistent sudo  
netfilter-persistent save
```

Sin este paso, aunque el Security List de OCI este abierto, el trafico no llega a la aplicacion. Es un error muy comun al hacer deploy en OCI.

6.3 Instalar dependencias del sistema

Para Oracle Linux 8:

```
sudo dnf update -y sudo dnf install -y python3 python3-pip git
```

Para Ubuntu 22.04:

```
sudo apt update && sudo apt upgrade -y sudo apt install -y python3-pip python3-venv  
git
```


7. Fase 5 — Deploy de la aplicacion

Con el servidor configurado, se procede a clonar el repositorio e instalar la aplicacion.

7.1 Clonar el repositorio

El nombre del repo comienza con guion (-), lo que requiere el flag -- en el comando cd para que bash no lo interprete como una opcion:

```
git clone https://github.com/ianjaner75/-alura-agente-rag-pro.git cd --  
-alura-agente-rag-pro
```

7.2 Crear entorno virtual e instalar dependencias

Se usa un entorno virtual para aislar las dependencias del proyecto del sistema operativo:

```
python3 -m venv venv source venv/bin/activate pip install --upgrade pip # Instalar  
PyTorch CPU (sin CUDA) para no consumir RAM innecesaria pip install torch  
--index-url https://download.pytorch.org/whl/cpu pip install -r requirements.txt
```

Por que torch+cpu: La version CUDA de PyTorch pesa ~2GB y requiere GPU. En una instancia ARM sin GPU, la version CPU es identica en funcionamiento pero consume menos memoria y se instala mas rapido.

7.3 Configurar variables de entorno

Crear el archivo .env con las credenciales de los servicios externos:

```
nano .env  
  
GROQ_API_KEY=tu_api_key_de_groq SUPABASE_URL=https://tu-proyecto.supabase.co  
SUPABASE_KEY=tu_service_role_key
```

Guardar con Ctrl+O > Enter > Ctrl+X. El archivo .env nunca debe subirse al repositorio de Git (.gitignore).

7.4 Iniciar la aplicacion

nohup hace que la aplicacion continúe corriendo aunque se cierre la sesion SSH. El & ejecuta el proceso en segundo plano:

```
nohup streamlit run app.py --server.port 8501 --server.address 0.0.0.0 &
```

7.5 Verificar que la aplicacion esta funcionando

```
# Verificar desde el mismo servidor curl http://localhost:8501 # Ver logs de la  
aplicacion tail -f nohup.out
```

Si curl responde con HTML, la aplicacion esta activa. Acceder desde el navegador en:
http://IP_PUBLICA:8501

7.6 Para detener la aplicacion

```
# Encontrar el PID del proceso ps aux | grep streamlit # Detenerlo kill  
PID_del_proceso
```

8. Problemas encontrados y soluciones

8.1 Ubuntu 22.04 no muestra shapes ARM en Bogota

Descripcion	Al seleccionar Ubuntu 22.04 como imagen, el campo Shape mostraba el mensaje 'No shapes are available for
Causa	La region Colombia Central (sa-bogota-1) tiene capacidad ARM limitada y en ese momento no habia disponibles
Solucion	Cambiar la imagen a Oracle Linux 8. Con esta imagen si aparecio el shape VM.Standard.A1.Flex disponible.

8.2 Service limits exceeded para 2 OCPU / 12 GB

Descripcion	Al intentar crear la instancia con 2 OCPUs y 12 GB, el error fue: 'The following service limits were exceeded: s
Causa	La cuenta OCI proporcionada por Alura/Oracle ONE tenia los limites de servicio ARM A1 en 0 para configurac
Solucion	Se intento reducir a 1 OCPU / 4 GB, pero entonces el error cambio a 'Out of capacity': habia cuota pero no cap

8.3 Out of host capacity en AD-1

Descripcion	Con 1 OCPU / 4 GB, OCI respondio 'Out of capacity for shape VM.Standard.A1.Flex in availability domain AD-
Causa	La region sa-bogota-1 tiene un solo Availability Domain y los servidores fisicos estaban al tope de capacidad.
Solucion	No hay solucion inmediata. Opciones: esperar disponibilidad (no garantizada antes del deadline), crear cuenta

8.4 La Home Region no se puede cambiar

Descripcion	Se busco la opcion de cambiar la region principal de la cuenta de Bogota a Ashburn.
Causa	Oracle no permite cambiar la Home Region una vez creada la cuenta. Es una restriccion permanente.
Solucion	No tiene solucion dentro de la misma cuenta. Requiere cuenta nueva.

8.5 Repo con guion al inicio (-alura-agente-rag-pro)

Descripcion	El comando 'cd -alura-agente-rag-pro' falla porque bash interpreta el guion como una opcion de comando.
Causa	Los nombres de directorio que empiezan con - son interpretados como flags por la shell.
Solucion	Usar 'cd -- -alura-agente-rag-pro'. El doble guion indica a bash que no hay mas flags.

9. Referencia rapida de comandos

SSH — Conexion al servidor

Accion	Comando
Conectar (Oracle Linux)	<code>ssh -i ~/.ssh/oci_rag_key opc@IP_PUBLICA</code>
Conectar (Ubuntu)	<code>ssh -i ~/.ssh/oci_rag_key ubuntu@IP_PUBLICA</code>
Generar llave SSH	<code>ssh-keygen -t ed25519 -C "oci-rag" -f ~/.ssh/oci_rag_key</code>
Ver clave publica	<code>cat ~/.ssh/oci_rag_key.pub</code>

Firewall del SO

Accion	Comando
Oracle Linux — abrir puerto	<code>sudo firewall-cmd --permanent --add-port=8501/tcp && sudo firewall-cmd --reload</code>
Ubuntu — abrir puerto	<code>sudo iptables -I INPUT -p tcp --dport 8501 -j ACCEPT</code>
Ubuntu — guardar reglas	<code>sudo netfilter-persistent save</code>

Dependencias

Accion	Comando
Oracle Linux — instalar	<code>sudo dnf update -y && sudo dnf install -y python3 python3-pip git</code>
Ubuntu — instalar	<code>sudo apt update && sudo apt install -y python3-pip python3-venv git</code>
Crear virtualenv	<code>python3 -m venv venv && source venv/bin/activate</code>
PyTorch CPU	<code>pip install torch --index-url https://download.pytorch.org/whl/cpu</code>
Dependencias del proyecto	<code>pip install -r requirements.txt</code>

Repositorio y aplicacion

Accion	Comando
Clonar repo	<code>git clone https://github.com/ianjaner75/-alura-agente-rag-pro.git</code>
Entrar al directorio	<code>cd -- -alura-agente-rag-pro</code>
Iniciar app en background	<code>nohup streamlit run app.py --server.port 8501 --server.address 0.0.0.0 &</code>
Ver logs	<code>tail -f nohup.out</code>
Verificar app local	<code>curl http://localhost:8501</code>
Ver procesos Streamlit	<code>ps aux grep streamlit</code>
Detener app	<code>kill \$(pgrep -f streamlit)</code>

10. Glosario de terminos OCI

Termino	Definicion
VCN	Virtual Cloud Network. Red privada virtual en OCI, equivalente a una VPC en AWS/GCP.
Subnet	Subdivision de la VCN. Puede ser publica (accesible desde internet) o privada.
Security List	Firewall a nivel de red en OCI. Define que trafico puede entrar y salir de una subnet.
Internet Gateway	Componente que conecta la VCN con internet. Necesario para subnets publicas.
Route Table	Tabla de enrutamiento que define hacia donde va el trafico de red.
Ingress Rule	Regla que controla el trafico ENTRANTE a la instancia.
Egress Rule	Regla que controla el trafico SALIENTE de la instancia.
Shape	Plantilla de hardware virtual en OCI: define CPUs, RAM y ancho de banda.
VM.Standard.A1.Flex	Shape ARM Ampere A1 de OCI. Flexible: se elige la cantidad de OCPUs y RAM.
OCPU	Oracle CPU. Una OCPU equivale aproximadamente a 2 vCPUs de otros proveedores.
Always Free	Nivel gratuito permanente de OCI que incluye 4 OCPUs ARM A1 y 24 GB RAM.
Home Region	Region principal de la cuenta OCI. No se puede cambiar una vez creada.
Availability Domain	Centro de datos fisico dentro de una region OCI. Bogota solo tiene 1 (AD-1).
Compartment	Contenedor logico para organizar recursos en OCI. Similar a proyectos en GCP.
Tenancy	La cuenta raiz de OCI. Todos los recursos pertenecen a una tenancy.
VNIC	Virtual Network Interface Card. Conecta la instancia a la VCN.
iptables/firewalld	Firewall del sistema operativo. Segundo nivel de seguridad, independiente del Security List.
nohup	Comando Linux que permite ejecutar procesos que continuan corriendo al cerrar SSH.
opc	Usuario por defecto de Oracle Linux en instancias OCI (equivale a 'ubuntu' en Ubuntu).